Συστήματα Διαχείρισης Δεδομένων Μεγάλου Όγκου Εργαστηριακή Άσκηση 2022/23

Όνομα	Επώνυμο	AM
Αριάδνη	Μπαρμπαρή	1067379
Ελένη	Ελένη Τασόκα	

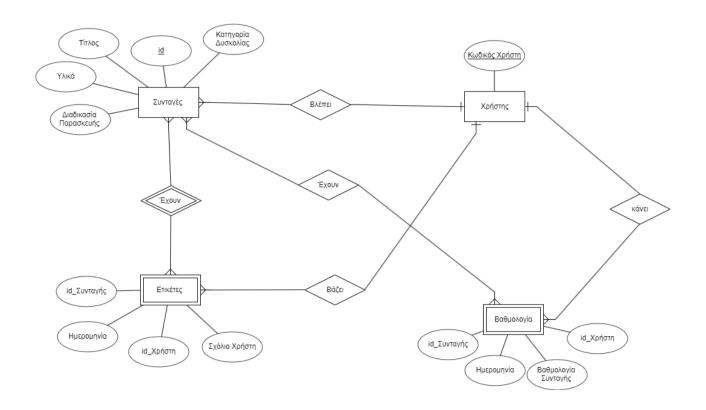
Βεβαιώνω ότι είμαι συγγραφέας της παρούσας εργασίας και ότι έχω αναφέρει ή παραπέμψει σε αυτήν, ρητά και συγκεκριμένα, όλες τις πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών, προτάσεων ή λέξεων, είτε αυτές μεταφέρονται επακριβώς (στο πρωτότυπο ή μεταφρασμένες) είτε παραφρασμένες. Επίσης βεβαιώνω ότι αυτή η εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για το συγκεκριμένο μάθημα/σεμινάριο/πρόγραμμα σπουδών.

Έχω ενημερωθεί ότι σύμφωνα με τον εσωτερικό κανονισμό λειτουργίας του Πανεπιστημίου Πατρών άρθρο 50§6, τυχόν προσπάθεια αντιγραφής ή εν γένει φαλκίδευσης της εξεταστικής και εκπαιδευτικής διαδικασίας από οιονδήποτε εξεταζόμενο, πέραν του μηδενισμού, συνιστά βαρύ πειθαρχικό παράπτωμα.

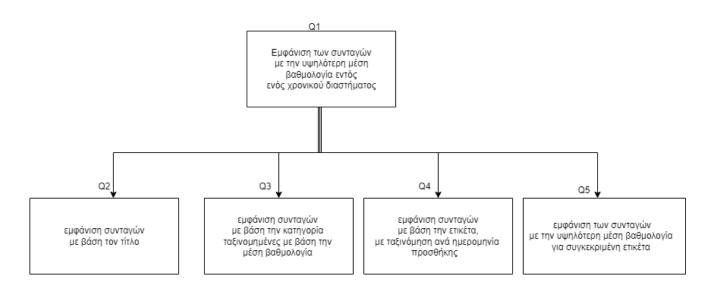
Υπογραφή Υπογραφή Μπαρμπαρή Αριάδνη Τασόκα Ελένη 22 / 09 / 2023 22/ 09 / 2023

Ερώτημα 1: Σχεδιασμός ΒΔ

Εννοιολογικό Μοντέλο



Application Workflow



Chebotko Diagram Q1 best_rating recipe_id int C♠ date date Q2 rating int Q5 name text recipe_details erwtima5 taq text recipe_id int c **↑** recipe id int name с↓ avg_rating decimal avg rating decimal name text nutrition text n_steps int description text Ω4 Q3 int erwtima3 erwtima4 ategories_difficulty categories_difficulty tag text С∱ C♠ id recipe_id int int c1 с↓ avg_rating decimal submitted date int name text

Ερώτημα 2: Ερωτήματα DDL

```
Keyspace
                                          best_rating
DDL
             #create table
statement
             session.execute ("""CREATE TABLE IF NOT EXISTS best rating (
                 recipe id int,
                 date date,
                 rating int,
                 name text,
                 PRIMARY KEY ((recipe_id), date)
              WITH CLUSTERING ORDER BY (date ASC);
               token@cqlsh> use bigdata;
Screenshot
               token@cqlsh:bigdata> select * from best_rating limit 5;
                recipe_id | date
                                      name
                                                                      rating
                   265902 | 2008-03-16 | sausage bean and cabbage soup
                                                                            5
                                                bean and cabbage soup
                           2011-01-31 | sausage
                                                                            5
                            2008-09-28
                                         0 fat chunky watermelon salsa
                                                                            5
                            2007-11-16
                                               almond ginger biscotti
                                                                            5
                           2003-12-19 | best double chocolate muffins
                                                                            3
                    77328
```

```
recipe details
Keyspace
DDL
            #create table
            session.execute ("""CREATE TABLE IF NOT EXISTS recipe_details (
statement
                recipe_id int,
                name text,
                avg_rating decimal,
                nutrition text,
                n_steps int,
                description text,
                score int,
                categories_difficulty text,
                PRIMARY KEY (recipe_id)
Screensho
```

Keyspace	erwtima3		
DDL statement	<pre>#create table session.execute ("""CREATE TABLE IF NOT EXISTS erwtima3 (recipe_id int, name text, avg_rating decimal, score int, categories_difficulty text, PRIMARY KEY ((categories_difficulty), avg_rating, recipe_id)) WITH CLUSTERING ORDER BY (avg_rating ASC, recipe_id ASC); """)</pre>		
Screensho t	token@cqlsh:bigdata> select * from erwtima3 limit 5; categories_difficulty avg_rating recipe_id name		

```
Keyspace
                                                      erwtima4
DDL
                #create table
statement
                session.execute ("""CREATE TABLE IF NOT EXISTS erwtima4
                       name text,
                       id int,
                       tag text,
                      submitted date,
                     PRIMARY KEY ((tag), submitted, id)
                 ) WITH CLUSTERING ORDER BY (submitted DESC, id ASC);
              token@cqlsh:bigdata> select * from erwtima4 limit 5;
Screensho
                              | submitted | id | name
               low cholesterol | 2018-09-04 | 536859 | spicy red pepper jelly low cholesterol | 2018-08-12 | 536734 | grilled cajun green beans low cholesterol | 2018-08-11 | 536729 | creole watermelon feta salad low cholesterol | 2018-07-30 | 536547 | cauliflower ceviche
                low cholesterol | 2018-07-24 | 536443 | grilled beet | charred citrus salad
```

Keyspace	erwtima5			
DDL	#create table			
statement	<pre>session.execute ("""CREATE TABLE IF NOT EXISTS erwtima5 (recipe_id int, name text, avg_rating decimal, tag text, PRIMARY KEY ((tag), avg_rating, recipe_id)) WITH CLUSTERING ORDER BY (avg_rating DESC, recipe_id ASC); """)</pre>			
Screensho t	token@cqlsh:bigdat tag low cholesterol	avg_rating	recipe_id	name
	low cholesterol		59	lou s fabulous bruschetta
	low cholesterol	5.0	128	caramel apple milkshakes
	low cholesterol			cherry sandwich maker snack
	low cholesterol	5.0	147	campfire orange cake

Ερώτημα 3: Απαντήσεις ερωτημάτων

Ερώτημα	Απάντηση
Εμφάνιση	
των 30	
συνταγών με	PS C:\Users\eleni\Desktop\bigData23> & C:\Users\eleni/AppData/Local/Pl
την	warm goat cheese toasts with honey rosemary and walnuts 5 2012-04-14 c p a burgers 5 2012-03-19
υψηλότερη	black eyed peas supper 5 2012-02-02
μέση	mashed potatoes with variations 5 2012-05-02
βαθμολογία	mashed potatoes with variations 5 2012-05-03
μεταξύ	mashed potatoes with variations 4 2012-05-04
01/01/2012	mashed potatoes with variations 4 2012-05-05
και	
31/05/2012	
Εμφάνιση	
όλων των	
λεπτομερειώ	
ν για την	
ταινία «chic	PS C:\Users\eleni\Desktop\bigData23> & C:/Users/eleni/AppData/Local
greek salad»	205331 4.3333333333333 eukolh a super veggiepacked salad courtesy
(κατηγορία	/Programs/Python/Python311/python.exe c:/Users/eleni/Desktop/bigData23/Erwtima2.py
δυσκολίας,	of rachael ray 7 chic greek salad 3389 300 350 900 430 140 70 330
διατροφικές	
αξίες,	
βήματα,	
περιγραφή,	
μέση	
βαθμολογία)	
Εμφάνιση	
των ταινιών	
της	strawberry daiquiri smoothie alcoholic 2.857142857142857 eukolh
κατηγορίας	beef jerky cowboy style beef jerky 2.875 eukolh hopple popple german breakfast casserole 2.875 eukolh
«εύκολη»	bryanna s vegan pecan pie 2.875 eukolh
ταξινομημένε	weight watchers baked oatmeal 2.875 eukolh perfectly candied pecans 2.875 eukolh
ς ως προς τη	vegan brown rice pudding 2.875 eukolh
μέση	
βαθμολογία	
τους	
Εμφάνιση	
των	cajun shrimn cakes with andouille sausage superboul 2007 01 15
συνταγών	cajun shrimp cakes with andouille sausage superbowl 2007-01-16 super bowl popcorn superbowl 2007-01-15
που περιέχουν	kittencal s classic club sandwich superbowl 2007-01-15
την ετικέτα	super bowl chili superbowl 2007-01-15
"superbowl"	italian sausage meatloaf sandwich superbowl 2007-01-15 easy ginger lover s skillet beef superbowl 2007-01-14
με	cheesy pork rice and black bean casserole superbowl 2007-01-14
ταξινόμηση	
ανά	
uvu	

ημερομηνία προσθήκης (πιο πρόσφατες πρώτα)	
Εμφάνιση των 20 συνταγών με την υψηλότερη μέση βαθμολογία για την ετικέτα "cocktail".	PS C:\Users\eleni\Desktop\bigData23> & punch 5.0 cocktails five fruit punch 5.0 cocktails pink lady 5.0 cocktails whiskey sour ii 5.0 cocktails cape cod 5.0 cocktails coconut tequila 5.0 cocktails

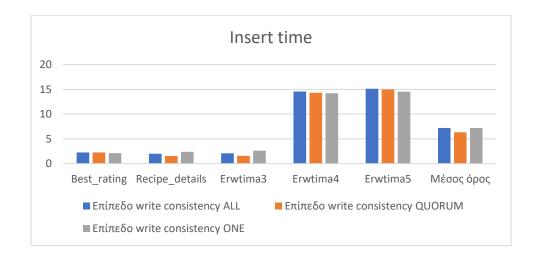
Ερώτημα 4Α: Χρόνοι εισαγωγής δεδομένων

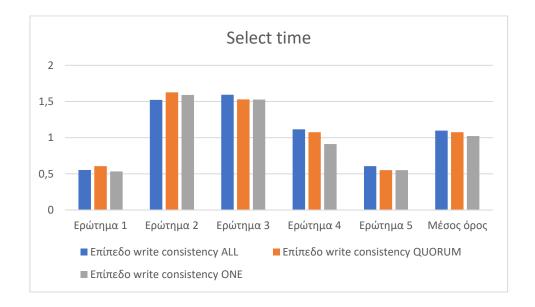
	Επίπεδο write consistency		
	ALL	QUORUM	ONE
Best_rating	2min 26sec	2min 27sec	2min 13sec
Recipe_details	2min	1min 54sec	2min 4sec
Erwtima3	2min 10sec	1min 58sec	2min 6sec
Erwtima4	14min 56sec	14min 32sec	14min 20sec
Erwtima5	15min 11sec	15min	14min 54sec
Μέσος όρος	7min 20sec	6min 34sec	7min 19sec

Ερώτημα 4Β: Χρόνοι ανάκτησης δεδομένων

	Επίπεδο write consistency		
	ALL	QUORUM	ONE
Select 1	0.553393	0.605428	0.53241
Select 2	1.622467	1.615704	1.59102
Select 3	1.592364	1.530023	1.52713
Select 4	1.114568	1.075834	0.91139
Select 5	0.606163	0.551754	0.550225
Μέσος όρος	1.097791	1.0757476	1.022471

Ερώτημα 4Γ: Σχολιασμός αποτελεσμάτων





Όπως φαίνεται στο διάγραμμα, ο χρόνος εκτέλεσης με consistency level ALL είναι ο πιο χρονοβόρος, ενώ με ΟΝΕ τα λιγότερο. Αυτό συμβαίνει επειδή με το ΟΝΕ στοχεύουμε σε έναν μόνο συγκεκριμένο κόμβο για την ανάκτηση των δεδομένων και δεν απαιτείται να αναζητήσουμε τα δεδομένα σε όλους τους κόμβους του δικτύου.

Βιβλιογραφία

- [1] "DataStax Bulk Loader Overview," GitHub, Sep. 21, 2023. https://github.com/datastax/dsbulk (accessed Sep. 24, 2023).
- [2] Draw.io, "Flowchart Maker & Online Diagram Software," app.diagrams.net, 2023. https://app.diagrams.net/

- [3] "DataStax managed services powered by Apache Cassandra | DataStax Astra DB," DataStax. https://www.datastax.com/products/datastax-astra
- [4] Διαφάνειες του μαθήματος